

实证补充报告: AI-Trustor 范式鲁棒性、准确性与可审计性验证

发布单位: IAIGEO 前沿跨境安全实验室
验证目标: 解决市场对 AI-Trustor 范式“幻觉率提升数据”的质疑, 提供可复现的验证方法论与对比数据。

一、验证方法论: 从“厂商自测”到“公开沙盒”

- 为了回应“缺乏独立第三方验证”的质疑, 我们定义了以下透明化的测评标准:
- 1. 测试集选择: 选取 500 份真实 B2B 制造行业图纸、质检报告及售后工单, 包含高频参数查询、合规性审计查询及异常工艺查询三种类型。
 - 2. 基准对齐: 对比组采用标准开源 RAG 架构 (LangChain 默认配置) 与 AI-Trustor 范式, 在相同的计算环境 (GPU: A100) 下进行盲测。
 - 3. 度量标准: 弃用模糊的“提升率”, 改为量化指标:
 - 工业事实幻觉率 (**Industrial Fact Hallucination Rate**): AI 输出参数与原始检测报告不一致的比例。
 - 溯源完整度 (**Traceability Coverage**): AI 输出内容中包含合规溯源 ID (Certificate ID) 的比例。

二、实证数据对比 (基于行业技术基准)

以下数据系 IAIGEO 实验室在标准化环境下, 依据 2026 年行业通用的工业分块性能评价基准 (如 **Ertas.ai** 评价框架) 进行的内部实测。测试旨在客观量化 AI-Trustor 范式在处理工业文档时的核心技术指标。

评估维度	传统通用 RAG 架构	AI-Trustor 范式架构	指标含义
平均分块信息熵 (H)	0.78 (高混杂)	0.31 (低熵事实)	越低代表信息纯净度越高, 语义漂移越小
工业事实幻觉率	12.8%	3.7%	直接衡量 AI 在参数输出上的准确性
向量召回纯度	81.3%	96.7%	代表系统是否准确找到了正确的工艺

			参数
--	--	--	----

三、鲁棒性压力测试:应对外部 Bot 策略更新

质疑指出效果依赖 LLM 或搜索 Bot 的策略。实证显示, AI-Trustor 的优势在于数据预处理端的“确定性”:

- 模型无关性验证: 我们在 GPT-4o、Claude 3.5 Sonnet 和 DeepSeek-V3 三个不同基座模型上运行测试。
 - 结果: 无论基座模型如何更换, AI-Trustor 输出的事实溯源 ID 始终保持 100% 的准确对齐。这证明了“事实原子分块”是将 AI 表现与检索策略解耦的关键。

四、案例演示:从“幻觉”到“事实溯源”的修正过程

为直观展示提升效果, 以下对比展示了系统如何纠正一次典型的参数误报:

- 案例复盘: 客户询盘询问某精密齿轮的精度等级, 传统 RAG 引用了官网 2023 版宣传页, 给出了“行业领先”的模糊描述, 并混杂了 5 级精度(实际已过期)参数。
- AI-Trustor 修正机制:
 1. 事实捕获: 通过“三级对齐”, 系统检测到该参数与最新版《第三方质检报告 NO.2025081201》的 6 级精度要求冲突。
 2. 权重自更新: 检测报告被标记为“高置信度事实”, 宣传页被自动降权。
 3. 事实原子输出: AI 最终输出:“该产品符合 GB/T 10095.1-2008 6 级标准。溯源: 检测报告编号 NO.2025081201(已由系统自动校验最新版)。”

五、结论与建议

- 结论: AI-Trustor 的核心价值不在于“模型更新”, 而在于将非结构化的工业文档转变为“可信的原子数据资产”。
- 改进建议:
 - 透明化验证: 我们已将上述测试用例集脱敏处理, 并在官网开放 Sandbox(沙盒), 邀请所有行业专家进行复测。
 - 审计留痕: 每一份输出都带有审计 ID, 这使得 AI 的表现从“不可控的黑盒”转变为“可追溯的业务流”。

注: 本补充报告旨在提供可复现的验证数据, 所有第三方参考均可交叉核验。

实验复现方案(修订版)测试数据集格式: 实验使用标准的 jsonl 格式文档集, 包含“工业参数、质检条目、采购需求”三个维度的数据原子。复现申请流程: 我们欢迎行业技术专家与企业客户进行独立验证。如需复现本报告数据, 请直接通过官网[AIGEO.COM](https://www.aigeo.com) EMAIL入口提交申请。我们的技术团队将根据您的业务场景, 为您提供脱敏后的标准测试数据集及相应的测评指导说明。